

Modern Data Warehouse Solution

Uçtan Uca Veri Ambarı ve Analitik Çözümü



Proje içeriğine erişmek için
taratın veya tıklayın.

Barış Anık



sonarcloud



Data Studio




Problem ve Yaklaşım

ERP ve CRM (CSV dosyası) ve API (JSON) kaynaklarından gelen müşteri, ürün ve satış verilerinin bütüncül bir yaklaşımla analiz edilebilmesi için merkezi bir yapıya ihtiyaç duyulmaktadır.


Mevcut Verinin Karakteristiği ve Zorluklar:

- **Format Uyumsuzluğu:** Veriler CSV ve JSON olmak üzere iki farklı formatta gelmektedir.
- **Düşük Veri Kalitesi:** ERP ve CRM kaynağından gelen verilerde doğal veri bozuklukları bulunmaktayken, API kaynağından elde edilen verilerde %40 oranında kasıtlı rastgele veri kalite sorunları simüle edilmiştir.
- **ID Çakışması Riski:** Farklı kaynaklardan gelen kayıtların birleştirilmesi (UNION) esnasında mükerrerlik riski bulunmaktadır.



Çözüm:


Verinin analitik süreçlere hazır, yüksek kaliteli hale getirilmesi için ELT ve görselleştirme süreçlerini kapsayan uçtan uca bir veri ambarı mimarisi tasarlanmıştır.



Versiyonlama ve Teknoloji Yığını

Proje üç temel versiyon üzerinde gelişmiştir. Her aşamada farklı kullanım senaryoları simüle edilmiştir.

	MVP	Local - Docker	Cloud
Depolama	SQL Server	SQL Server	Google BigQuery
Verinin İçe Aktarımı	SQL - Python	SQL - Python	Python
Simülasyon	Python	Python	Python
Dönüşüm	SQL	dbt Core	dbt Cloud
Test	pytest	pytest & dbt Core	pytest & dbt Cloud
Kod Kalitesi ve Güvenlik	-	-	Sonar Cloud
Orkestrasyon	-	Apache Airflow	GitHub Actions
CI / CD	-	-	GitHub Actions
Raporlama	-	Metabase	Google Data Studio



Veri Ambarı Mimarisi Seçimi - Neden Madalyon Mimarisi?

- **Düşük Depolama Maliyeti:** 177 bin satırlık ham veri hacmi nedeniyle madalyon mimarisinde yer alan veri tekrarı durumunun depolama maliyetine olumsuz bir etkisi bulunmamaktadır.
- **İzlenebilirlik:** Veri kalite evriminin geriye dönük gözlemlenmesini mümkün kılar. dbt ile her katmanda farklı dönüşüm standartları kontrol edilir.
- **Esnek Erişim:** Sorumluluk ayrımı (separation of concerns) kapsamında veri etrafında toplanan paydaşların (veri mühendisi, veri analisti, iş birimleri ve iş zekası araçları) ilgili katmanlardan ihtiyacı olan veriye erişiminin madalyon mimarisiyle kolayca sağlanabilmektedir.

Madalyon mimarisinde veri üç katmanda bulundurulmaktadır:

BRONZE

Ham verinin tutulduğu katmandır.





SILVER

Ham verinin standardize edildiği, çoklu kayıtlardan temizlendiği steril katmandır.




GOLD

Silver katmandan elde edilen verilerin iş birimi odaklı birleştirildiği analitik çözümlere hazır katmandır.





Veri Sözlüğü ve İlişki Şeması



Proje Kararları

Ham Veri İçeri Aktarım Stratejisi

Bronze katmana veri aktarımı yapılırken tam yükleme (full load) stratejisi benimsenmiştir. Projede kullanılan veri kaynaklarının sürekli güncellenmemesi ve düşük boyutlu olması nedeniyle yalnızca güncel verilerin yüklenmesi stratejisi (incremental load) kullanılmamıştır.

Gold Katmanda Surrogate Key Kullanımı

Gold katmanda kayıtlara benzersiz id değeri tanımlaması işleminde SQL'de bulunan ROW_NUMBER fonksiyonu yerine dbt_utils kütüphanesine bağlı generate_surrogate_key metodu kullanılmıştır. Bu sayede satırlara verilen id değerinin her veri yüklenmesi anında aynı şekilde sonuçlanması sağlanmıştır; projenin tekrarlanabilirliğini pekiştirmiştir.

dbt Core → dbt Cloud Geçişi

Severity: Warn Durumundaki dbt Testleri

[illegible]



Test ve Güvenlik



Veri ambarında yer alan katmanlar arası veri dönüşümlerinden sonra kabul kriterlerine uygunluğu ölçmek amacıyla hem built-in hem de custom testler kullanılmaktadır. Testi geçemeyen kayıtlar akışı bozmaz; audit tablolarında karantina altına alınır.



Ham verinin içe aktarımı ve simülasyon süreçlerinde kullanılan Python fonksiyonlarının doğruluğu pytest birim testleri ile güvence altına alınır.



CI/CD süreçlerine entegre şekilde, geliştirilen kodları sürdürülebilirlik, güvenlik ve güvenilirlik (Quality Gate) standartları kapsamında analiz eder.

reliability A

maintainability A

security A

vulnerabilities 0



Projeye dair tüm test ve veri güncelleme süreçleri GitHub Actions tarafından yönetilmektedir.

All checks have passed			×
3 successful and 1 skipped checks			
✓	CI / Python Unit Tests (push)	Successful in 39s	Details
✓	SonarCloud Code Analysis	Successful in 18s - Quality Gate passed	Details
⌛	CI / Trigger dbt Cloud job (push)	Skipped	Details
✓	CI / dbt Parse Check (push)	Successful in 41s	Details



Satış

VERİ KAYNAKLARI


- dim_products
- dim_customers
- fact_sales
- Özel sorgular (view ve Data Studio özel sorguları)

BULGULAR

- ❖ Satışlar Ocak 2014'e kadar artış trendindedir.
- ❖ Teslimat süresi kış aylarında artış eğilimindedir.
- ❖ En çok satış yapılan ülke Amerika, en çok satış yapılan kategori taşıtlardır.



Dashboard'a erişmek için taratın veya tıklayın.





Müşteri

VERİ KAYNAKLARI


- dim_customers
- fact_sales

BULGULAR

- ❖ Müşterilerin ilk %10'u gelirin %45'ini sağlamaktadır.
- ❖ Müşteriler yoğunlukla Kuzey Amerika ve Avustralya bölgelerinde ikamet etmektedir.
- ❖ Genel müşteri kitlesi 35 yaş ve üzeridir ancak API kaynağından gelen müşteriler çoğunlukla 25-34 yaş grubundadır.



Dashboard'a erişmek için taratın veya tıklayın.





VERİ KAYNAKLARI


- dim_products
- dim_customers
- fact_sales
- Özel sorgular (view)

BULGULAR

- ❖ Avustralya'da bisiklet satışı global ortalamaya kıyasla en yüksek tercih oranına sahip.
- ❖ Aksesuarlar ve giyim ürünleri en yüksek kâr marjını sağlamakta.
- ❖ CSV kaynağı 4 kategori odağında dağılım gösterirken bu durum API kaynağında 25 kategoriye çıkmaktadır.



Dashboard'a erişmek için taratın veya tıklayın.





Veri Kalitesi

VERİ KAYNAKLARI


- **dq_test_log:** dbt test sonuçları
- **dq_ground_truth:** API verisinde yapılan kasıtlı veri bozulması işlemine ait kayıtlar
- Özel sorgular (view)

BULGULAR

- ❖ Ürün ve sipariş kayıtlarında ürün adının olmamasına bağlı %1.7'lik veri kaybı bulunmaktadır.
- ❖ Tüm dbt testleri hatasız sonuçlanmış, 2600 satırda warning seviyeli uyarıyla takip edilen kayıtlar bulunmaktadır.



Dashboard'a erişmek için taratın veya tıklayın.





İş Etkisi ve Kazanımlar

GitHub Actions CI/CD hattına entegre edilen test otomasyonları ve SonarCloud kod analizi sayesinde üretim ortamındaki bakım maliyetleri ve güvenlik riskleri minimuma indirilmiştir.

Sürdürülebilirlik: dbt sayesinde projeye yeni eklenecek veri kaynaklarının entegrasyonu dakikalar içerisinde tamamlanabilmektedir.

202

OTOMATİK DBT TESTİ

22


BİRİM TESTİ

0

HATALI VERİ SIZINTISI

0

GÜVENLİK AÇIĞI



- ✓ Veri dönüşüm sürecinde geriye dönük takip edilebilirlik
- ✓ Esnek erişim
- ✓ Düşük depolama maliyeti
- ✓ Analiz edilebilir merkezi veri

Teşekkürler

Projeye dair kapsamlı bilgi almak için [GitHub sayfasını](#) ziyaret edebilir, sorularınız için [benimle iletişime geçebilirsiniz](#).

Barış Anık



Proje içeriğine erişmek için taratın veya tıklayın.



barisanik



baris-anik



barisanik@gmail.com